



UNIVERSIDADE DA CORUÑA

# Neural Image Compression (NIC): El fin de la era JPEG

Compresión Neuronal de Imágenes

Rubén Fernández Farelo   David Gonçalves Álvarez   Daniel Quintillán  
Quintillán

Brais Rodríguez González   Álvaro Santiso Freire

Introducción á Xestión Multimedia  
Universidade da Coruña

Mayo 2026

El Problema y Cambio de Paradigma

Fundamentos Técnicos

Evolución y Resultados

Retos y Casos de Uso

Estándar JPEG AI, Futuro y Conclusiones

# **El Problema y Cambio de Paradigma**

---

## Internet colapsa bajo el peso visual

El 80 % del tráfico de Internet es contenido visual (imágenes y vídeo).

- Los códecs clásicos (JPEG, HEVC) se basan en la **DCT** y procesamiento por bloques.
- Diseñados manualmente hace décadas, han alcanzado su **techo matemático**.
- Resultado: **artefactos de bloque** visibles a tasas bajas de bits.
- No aprovechan la redundancia semántica de la imagen.

# El Paradigma del Aprendizaje (NIC)

## Neural Image Compression

Dejar que una **red neuronal profunda** aprenda automáticamente la representación más eficiente de la imagen, sin reglas diseñadas a mano.


### Pregunta clave:

1. ¿Es **técnicamente** viable sustituir a JPEG hoy?
2. ¿Es **industrialmente** viable su despliegue a escala?

# Fundamentos Técnicos

---

# El Autoencoder Variacional (VAE)



**Figura 1:** Arquitectura del Autoencoder Variacional para NIC.

## Función de pérdida fundamental

$$L = R + \lambda \cdot D$$

- $R$  (*Rate*): Número de bits necesarios para codificar la representación latente.
- $D$  (*Distortion*): Error de reconstrucción (calidad perdida).
- $\lambda$ : Parámetro que **equilibra** compresión vs. calidad.

Un  $\lambda$  alto prioriza calidad; un  $\lambda$  bajo prioriza compresión.



# El Reto de la Cuantización

- La cuantización (redondeo a enteros) es **necesaria** para obtener un bitstream discreto.
- Problema: crea una función escalera con **gradiente nulo**  $\rightarrow$  rompe la retropropagación.

## Solución: Ruido uniforme aditivo

Durante el entrenamiento, se sustituye el redondeo por **inyección de ruido uniforme**  $\mathcal{U}(-0,5, 0,5)$ , creando un sustituto diferenciable.


- En inferencia se usa el redondeo real.
- Permite entrenar el sistema end-to-end con descenso de gradiente.

# **Evolución y Resultados**

---

- **Primera generación:** CNNs — capturan patrones *locales* eficientemente.
- **Segunda generación: Vision Transformers (ViT)** — entienden el *contexto global* mediante mecanismos de **atención**.
- La atención permite ponderar regiones distantes de la imagen para una codificación más eficiente.

# Evolución Arquitectónica: Diagrama




**Figura 2:** De CNNs a Vision Transformers en compresión neuronal.

## **BD-Rate: 65 % de ahorro**

Los modelos NIC actuales ahorran un **65 % de bits** respecto a JPEG manteniendo la misma calidad visual en el dataset Kodak.

- **BD-Rate:** ahorro porcentual de bits para la misma calidad.
- Superan a JPEG y también a HEVC/Intra en benchmarks relevantes.
- Rendimiento consistente en distintos tipos de contenido.


# Resultados: Curva Tasa-Distorsión



**Figura 3:** Curva Tasa-Distorsión: NIC vs. códecs clásicos.

- **Fine-tuning** para dominios específicos:
  - Radiografías médicas.
  - Imágenes satelitales.
  - Contenido artístico.
- Métricas perceptuales como **MS-SSIM** optimizan para el ojo humano.
- Degradación **suave y gradual**, sin artefactos de bloque.

# Comparativa perceptual



**Figura 4:** Comparación perceptual: NIC vs. JPEG a misma tasa de bits.



# Retos y Casos de Uso

---

- Modelos autorregresivos: tardan **segundos por imagen** en una CPU convencional.
- Complejidad computacional  $\gg$  decodificadores JPEG.
- **Necesidad absoluta** de hardware dedicado:
  - NPU (Neural Processing Unit).
  - GPU con soporte de inferencia optimizada.
  - Aceleradores ASIC específicos.

## Barrera de adopción

Sin aceleración hardware, NIC no es viable para decodificación en tiempo real.

## Almacenamiento WORM en la nube

Netflix / Meta: codifican una vez, leen millones de veces. El coste de codificación se amortiza masivamente.

- **VCM** (Video Coding for Machines):
  - Compresión optimizada para visión artificial.
  - Coches autónomos, vigilancia, drones.
  - La máquina no necesita “calidad visual humana”.
- Archivos digitales de larga duración.
- Streaming adaptativo con decodificación en servidor.

## Peligro: contenido inventado

A tasas de bits extremadamente bajas, los modelos generativos **inventan texturas realistas pero falsas** (“alucinaciones”).

- La imagen reconstruida *parece* correcta, pero contiene detalles ficticios.
- **Inasumible** en dominios críticos:
  - Imágenes médicas (diagnóstico erróneo).
  - Evidencia forense (pruebas judiciales).
  - Cartografía y teledetección.
- Requiere métricas de fidelidad estrictas, no solo perceptuales.

# **Estándar JPEG AI, Futuro y Conclusiones**

---

## ISO/IEC 6048-1 — JPEG AI

Primer estándar de compresión de imagen basado en redes neuronales, **libre de regalías**.

- Adopción en silicio:
  - Apple Neural Engine.
  - Qualcomm Hexagon NPU.
  - MediaTek APU.
- Integración con **C2PA / JPEG Trust**:
  - Autenticidad y procedencia de contenido.
  - Defensa contra Deepfakes.
  - Cadena de custodia criptográfica.




# Tendencias Futuras

| Modelos de Difusión Generativa           | Arquitecturas Omni-modales                               | Co-diseño Hardware-Software                    |
|------------------------------------------|----------------------------------------------------------|------------------------------------------------|
| Tensor latente guía proceso de Denoising | Códecs Imagen-Video (DCVC-UF)                            | Viabilidad en dispositivos de usuario          |
| CoD                                      | Transformers de Difusión y LLMs (OneDiffusion, UniVideo) | Minimizar modelo (GETA, cuantización 4/8 bits) |
| OSCAR                                    |                                                          | Velocidad de respuesta (KV-Cache)              |

**Tabla 1:** Tendencias futuras

# Conclusión: Despliegue “Core-to-Edge”



**Figura 5:** Despliegue Core-to-Edge de compresión neuronal.



**¡Gracias por su atención!**