



UNIVERSIDADE DA CORUÑA

Neural Image Compression (NIC): El fin de la era JPEG

Compresión Neuronal de Imágenes

Rubén Fernández Farelo David Gonçalves Álvarez Daniel Quintillán
Quintillán

Brais Rodríguez González Álvaro Santiso Freire

Introducción á Xestión Multimedia
Universidade da Coruña

Mayo 2026

El Problema y Cambio de Paradigma

Fundamentos Técnicos

Evolución y Resultados

Retos y Casos de Uso

Estándar JPEG AI, Futuro y Conclusiones

El Problema y Cambio de Paradigma

Internet colapsa bajo el peso visual

El 80 % del tráfico de Internet es contenido visual (imágenes y vídeo).

- Los códecs clásicos (JPEG, HEVC) se basan en la **DCT** y procesamiento por bloques.
- Diseñados manualmente hace décadas, han alcanzado su **techo matemático**.
- Resultado: **artefactos de bloque** visibles a tasas bajas de bits.
- No aprovechan la redundancia semántica de la imagen.

Neural Image Compression

Dejar que una **red neuronal profunda** aprenda automáticamente la representación más eficiente de la imagen, sin reglas diseñadas a mano.

Pregunta clave:

1. ¿Es **técnicamente** viable sustituir a JPEG hoy?
2. ¿Es **industrialmente** viable su despliegue a escala?

Fundamentos Técnicos

El Autoencoder Variacional (VAE)




Figura 1: Arquitectura del Autoencoder Variacional para NIC.

Función de pérdida fundamental

$$L = R + \lambda \cdot D$$

- R (*Rate*): Número de bits necesarios para codificar la representación latente.
- D (*Distortion*): Error de reconstrucción (calidad perdida).
- λ : Parámetro que **equilibra** compresión vs. calidad.

Un λ alto prioriza calidad; un λ bajo prioriza compresión.

El Reto de la Cuantización

- La cuantización (redondeo a enteros) es **necesaria** para obtener un bitstream discreto.
- Problema: crea una función escalera con **gradiente nulo** → rompe la retropropagación.

Solución: Ruido uniforme aditivo

Durante el entrenamiento, se sustituye el redondeo por **inyección de ruido uniforme** $\mathcal{U}(-0,5, 0,5)$, creando un sustituto diferenciable.

- En inferencia se usa el redondeo real.
- Permite entrenar el sistema end-to-end con descenso de gradiente.

Evolución y Resultados

- **Primera generación:** CNNs — capturan patrones *locales* eficientemente.
- **Segunda generación: Vision Transformers (ViT)** — entienden el *contexto global* mediante mecanismos de **atención**.
- La atención permite ponderar regiones distantes de la imagen para una codificación más eficiente.

Evolución Arquitectónica: Diagrama




Figura 2: De CNNs a Vision Transformers en compresión neuronal.

Resultados cuantitativos vs. JPEG

BD-Rate: 65 % de ahorro

Los modelos NIC actuales ahorran un **65 % de bits** respecto a JPEG manteniendo la misma calidad visual en el dataset Kodak.

- **BD-Rate:** ahorro porcentual de bits para la misma calidad.
- Superan a JPEG y también a HEVC/Intra en benchmarks relevantes.
- Rendimiento consistente en distintos tipos de contenido.

Resultados: Curva Tasa-Distorsión




Figura 3: Curva Tasa-Distorsión: NIC vs. códecs clásicos.

- **Fine-tuning** para dominios específicos:
 - Radiografías médicas.
 - Imágenes satelitales.
 - Contenido artístico.
- Métricas perceptuales como **MS-SSIM** optimizan para el ojo humano.
- Degradación **suave y gradual**, sin artefactos de bloque.

Comparativa perceptual



(a) Ours (0.2149 bpp)



(b) Scale-only (0.2205 bpp)



(c) BPG (0.2352 bpp)



(d) JPEG (0.2309 bpp)

Figura 4: Comparación perceptual: NIC vs. JPEG a misma tasa de bits.

Retos y Casos de Uso

- Modelos autorregresivos: tardan **segundos por imagen** en una CPU convencional.
- Complejidad computacional $\gg$ decodificadores JPEG.
- **Necesidad absoluta** de hardware dedicado:
 - NPU (Neural Processing Unit).
 - GPU con soporte de inferencia optimizada.
 - Aceleradores ASIC específicos.

Barrera de adopción

Sin aceleración hardware, NIC no es viable para decodificación en tiempo real.

Almacenamiento WORM en la nube

Netflix / Meta: codifican una vez, leen millones de veces. El coste de codificación se amortiza masivamente.

- **VCM** (Video Coding for Machines):
 - Compresión optimizada para visión artificial.
 - Coches autónomos, vigilancia, drones.
 - La máquina no necesita “calidad visual humana”.
- Archivos digitales de larga duración.
- Streaming adaptativo con decodificación en servidor.

Peligro: contenido inventado

A tasas de bits extremadamente bajas, los modelos generativos **inventan texturas realistas pero falsas** (“alucinaciones”).

- La imagen reconstruida *parece* correcta, pero contiene detalles ficticios.
- **Inasumible** en dominios críticos:
 - Imágenes médicas (diagnóstico erróneo).
 - Evidencia forense (pruebas judiciales).
 - Cartografía y teledetección.
- Requiere métricas de fidelidad estrictas, no solo perceptuales.

Estándar JPEG AI, Futuro y Conclusiones

ISO/IEC 6048-1 — JPEG AI

Primer estándar de compresión de imagen basado en redes neuronales, **libre de regalías**.

- Adopción en silicio:
 - Apple Neural Engine.
 - Qualcomm Hexagon NPU.
 - MediaTek APU.
- Integración con **C2PA / JPEG Trust**:
 - Autenticidad y procedencia de contenido.
 - Defensa contra Deepfakes.
 - Cadena de custodia criptográfica.



Tendencias Futuras

Modelos de Difusión Generativa	Arquitecturas Omni-modales	Co-diseño Hardware-Software
Tensor latente guía proceso de Denoising	Códecs Imagen-Video (DCVC-UF)	Viabilidad en dispositivos de usuario
Marco CoD	Transformers de Difusión y LLMs (OneDiffusion, UniVideo)	Minimizar modelo (GETA, cuantización 4/8 bits)
Codec OSCAR		Velocidad de respuesta (KV-Cache)

Tabla 1: Tendencias futuras

Conclusión: Despliegue “Core-to-Edge”




Figura 5: Despliegue Core-to-Edge de compresión neuronal.

¡Gracias por su atención!